

基于最小回环检测的多车协同SLAM框架

李博洋¹, 刘思健¹, 崔明月¹, 赵治豪², 黄 凯¹

(1. 中山大学计算机学院, 广东广州 510006; 2. 中山大学深圳研究院, 广东深圳 518057)

摘 要: 为了提升自动驾驶车辆的感知效率和准确率, 解决协同感知算法中对协同条件的限制和多源数据融合等问题, 本文引入基于激光雷达的即时定位与建图(Simultaneous Localization and Mapping, SLAM)算法, 提出面向自动驾驶的多车协同SLAM框架. 首先, 车辆运行单车SLAM, 构建本地约束并共享地图和位姿数据. 同时车辆接收并处理其他车的数据, 若其他车辆与本车已建立坐标系转换关系则直接完成数据融合, 否则基于重叠区域相似点云配准解算多车坐标转换关系. 采用图的连通分支和生成森林理论跟踪数据融合情况并构建多车回环约束, 基于通用图优化(General Graph Optimization, G2O)理论对全局地图优化. 真实场景与KITTI数据集的实验结果表明, 本文的框架无需构建包含所有车辆相对位姿的全局坐标系或满足多车相遇等约束条件, 即可实现多车协同SLAM, 并在SLAM的效率和准确率等指标上具有优势.

关键词: 协同SLAM; 车车协同通信; 数据融合; 回环检测; 激光雷达; 自动驾驶

中图分类号: TP391

文献标识码: A

文章编号: 0372-2112(2021)11-2241-10

电子学报URL: <http://www.ejournal.org.cn>

DOI: 10.12263/DZXB.20200951

Multi-Vehicle Collaborative SLAM Framework for Minimum Loop Detection

LI Bo-yang¹, LIU Si-jian¹, CUI Ming-yue¹, ZHAO Zhi-hao², HUANG Kai¹

(1. School of Computer Science and Engineering, Sun Yat-sen University, Guangzhou, Guangdong 510006, China;

2. Shenzhen Institute, Sun Yat-sen University, Shenzhen, Guangdong 518057, China)

Abstract: In order to improve the perception efficiency and accuracy of autonomous driving vehicles, and to solve the limitations which correspond to the conditions and the multi-source data fusion, this paper advocates a cooperative SLAM(Simultaneous Localization and Mapping) framework for autonomous driving. Firstly, each vehicle runs single SLAM algorithm, builds the local constraints and shares the map and pose. Meanwhile, each vehicle receives and handles data from others. If the coordinate relationship has been established, the coming data is directly fused. Otherwise, the relationship is computed based on the point clouds registration in overlapping areas. The connection components and spawn forest are adopted to track and build the multi-vehicle loop constraint. General Graph Optimization algorithm (G2O) is used to optimize the global map. Experiments based on real world and KITTI dataset show that our framework outperforms relevant SLAM systems, relaxing the conditions of providing relative poses in initial stage and vehicles encountering.

Key words: cooperative slam; vehicle-to-vehicle (V2V); data fusion; loop detection; light detection and ranging; autonomous driving

1 引言

在自动驾驶中, 对环境的三维感知与定位具有重要意义. SLAM算法基于激光雷达等传感器感知环境, 针对三维空间构建增量式点云地图, 基于地图和里程计完成实时定位^[1-3], 因而被广泛应用在自动驾驶中. SLAM分为前端和后端两个部分, 前端基于特征提取与

匹配, 估计相邻两帧的坐标变换并构建增量式地图, 后端通过构建的约束条件对前端的运算结果进一步优化, 从而得到精确的结果.

面向单辆车的SLAM研究已经较为成熟, 然而单车SLAM的累积误差将随着算法运行的时间和累积里程的增加而增加. 此外, 单车SLAM需要完整遍历整个区

域才能完成建图,这些限制条件约束了SLAM的运行效率.多车协同SLAM充分利用多车的地图与位姿数据,从而将来源于不同坐标系的数据融合成为全局一致的三维空间信息^[4,5].在多车协同SLAM中,每辆车与其他车共享并融合地图与位姿数据,使自身获取更多对环境的感知信息.同时基于多车的感知数据构造约束条件,完成对自身位姿与地图的纠正,进而获得更好的感知结果^[6].

多车协同SLAM尚未被广泛应用.在多车数据融合时,需要计算多车间的坐标系转换关系.为了解决此问题,可以通过构建全局坐标系^[7,8].但此条件过于苛刻,难以满足.另一种条件是为协同SLAM创造相遇机会,使多车在相遇区域基于对地标的共同观测计算坐标系转换关系^[9].在这种条件下,若多车没有直接相遇,则无法完成协同SLAM.闭环检测是协同SLAM的重要组成部分,通过闭环检测添加约束,能够有效纠正SLAM的累计误差,但针对多车协同SLAM的闭环检测尚未有较多研究.

为解决以上问题,本文提出并实现面向自动驾驶的多车协同SLAM框架.本文在多种场景下进行相关实验并分析.实验结果表明,本文提出的协同SLAM框架运行效率和准确率均有所提高.

2 相关工作

针对多车协同SLAM的研究,包括单车SLAM,多车坐标系统一与数据融合,多车回环检测和后端优化等三个方面.单车SLAM包括:仅包含前端的SLAM和包含前后端的完整SLAM.

仅包含前端的SLAM对输入数据进行特征提取,求解相邻两帧的坐标变换和运动关系.激光雷达里程计与建图^[10]及其衍生算法^[11]对激光点云提取边缘与平面特征,构建点、线和平面间的约束,通过迭代估算两帧的位姿变换^[12],从而构建地图与估算里程.文献^[13]基于平面参数空间和统计信息网格提取平面特征并匹配,根据匹配估计位姿与建图.基于约束分析和自适应加权的SLAM^[14],通过融合边缘与平面特征提升了位姿估计的准确性.包含前后端完整的SLAM将位姿抽象为节点,将节点间的约束抽象为边,基于前端的计算结果,后端通过优化模型优化所有节点的位置,使观测值和估计值的差值最小^[15,16].基于改进的粒子滤波器^[17]解决了创建大地图时的计算和存储负担太重的问题.基于约束的无色卡尔曼滤波方法^[18]解决了SLAM特征图的更新问题.基于随机梯度下降的方法^[19]修正了大场景下的SLAM位姿图.基于层次优化位姿图^[20]通过构建两层位姿图降低后端的计算量.

多车坐标系统一与数据融合是协同SLAM的关键

环节,每辆车将来自其他车的数据融合到本地坐标系中^[21].这一步骤将根据融合的条件进行对应处理^[22].若各车之间的相对初始位姿已知,则可直接进行数据融合,此条件无需考虑坐标系统一问题.但此条件难以满足.在未知相对姿态的情况下,基于数据关联中的非离群值数据配对,可以计算得到多车的相对姿态^[23],此方法需传输增量式地图进行完整地图匹配计算,对带宽和算力资源要求较高.此外,通过创造多车相遇条件^[9,24],将相遇区域地图作为锚点进行数据交换,解算得到坐标系转换关系^[25].此方法需创造多车相遇条件,未相遇的车辆无法交换数据,从而限制了协同SLAM的条件.

针对多车回环检测和后端优化,CAE-RLSM^[26]采用一对多的增量式线段合并算法和全局地图调整优化,解决增量式地图构建中的冗余问题和闭环检测的全局地图调整优化问题.在假设多车转换关系已知的前提下,文献^[27]提出结合最大似然估计和蒙特卡洛估计的闭环检测算法.基于受限因子图的后端优化方法^[28]通过对多车观测的地标构建约束,对融合的全局地图完成后端优化.

3 多车协同SLAM框架

3.1 框架概述

本文提出的多车协同SLAM框架如图1所示.该框架包含了基于扫描匹配和图优化的单车SLAM,针对多车协同SLAM的数据共享,多车坐标系统一与数据融合和多车协同SLAM的闭环检测与优化.

每辆车在运行单车SLAM,前端完成里程计估计和建图,后端通过本地约束和闭环检测优化前端数据.同时,将优化后的地图数据发送到通信接口的数据提供者模块,与其他车共享.

车辆通过通信接口的接收者模块接收数据,查询数据包提供者与自身是否建立坐标系转换关系.根据查询结果,更新坐标系转换矩阵,将接收到其他车的感知数据存入暂存数据队列或直接融合到本地地图中.基于重叠区域的相似点云检测和配准以及变换矩阵的传递性,完成多车坐标系的统一.

经过坐标转换后的数据被融合到本地地图中,每辆车基于图的连通分支和最小生成森林理论构建多车协同的回环约束,并开展全局的优化,从而得到融合后全局一致的SLAM结果.

3.2 基于扫描匹配和图优化的单车SLAM

扫描匹配算法提取点云特征,通过迭代计算相邻两帧的变换关系,建立增量式地图.激光雷达里程计与建图是高实时但未包含后端优化的扫描匹配算法,本文对其优化后作为本框架SLAM的前端.

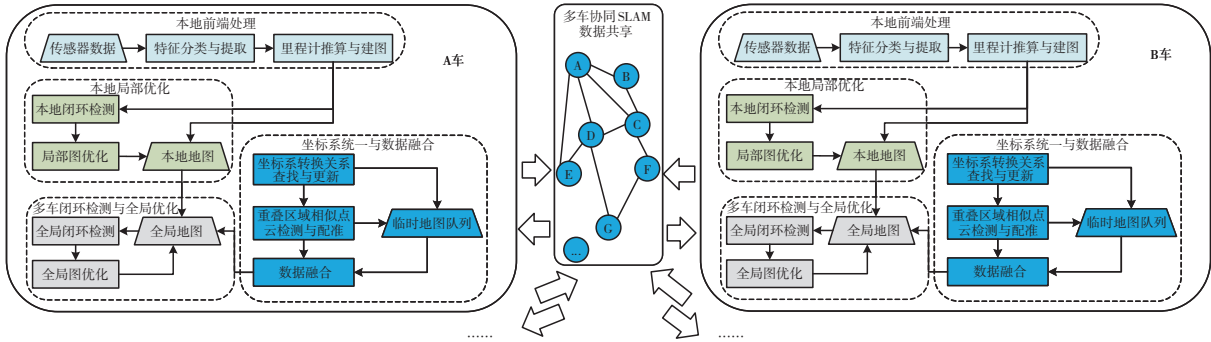


图1 多车协同SLAM算法框架

针对后端优化,将连续时间或空间内感知数据作为关键帧抽象成节点,将节点间约束抽象为边.其中,约束包括相对观测约束和单车回环约束.相对观测约束通过前端直接构建.单车回环约束,通过基于点云几何形状特征的正态分布变换匹配算法,构建基于正态分布统计结果的外观描述子与场景直方图,检测回环区域.

图2描述了本文的单车SLAM算法流程.为了平衡前端匹配,回环检测以及后端优化速率,本文使用两个队列作为数据缓冲.在前端,感知数据经过里程计推算后获取当前位姿相对上一时刻的距离与角度,当累积距离或角度增量满足阈值时,将点云帧和位姿数据作为关键帧推入队列 Q_1 ,并构建相对观测约束.队列 Q_2 存放历史关键帧,将 Q_1 的关键帧在 Q_2 中进行本地回环检测.若检测失败,则未发生闭环,将 Q_1 数据推入 Q_2 ,清空 Q_1 .若检测成功,构建单车回环约束,触发局部图优化纠正位姿.通过此缓冲机制,平衡前端与后端工作速率.

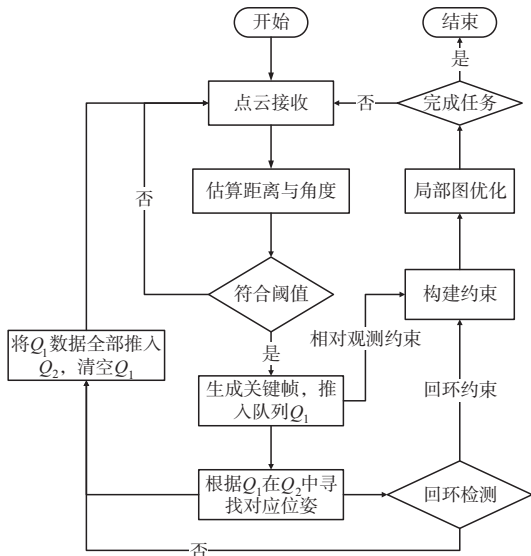


图2 基于扫描匹配和图优化的单车SLAM流程

3.3 多车协同SLAM的数据共享

在多车协同SLAM中,每辆车同时作为数据包提供者和接收者两种角色.数据包提供者在 t 时刻维护:本地局部地图 M^t 、已建立坐标转换关系的链表 L 、以及存储对应变换矩阵的链表 X .数据包 P_{ID}^t 的定义如式(1)所示,数据包包含 t 时刻最近的若干帧地图和位姿数据 $M^{[t-\tau_0, t]}$,链表 L 和 X .帧的数量由超参数 τ_0 来控制. τ_0 越大,数据帧越多,信息更丰富,但计算开销和网络传输压力也增大.由于 P_{ID}^t 中包含了 L 和提供者的ID,接收者通过坐标变换矩阵的传递性与未知车辆间接建立关系,有利于多车坐标系的统一和一致性的保持.

$$P_{ID}^t \leftarrow (M^{[t-\tau_0, t]} \cup L \cup X)_{ID}^t \quad (1)$$

此外,每辆车维护 t 时刻尚未融合到本地的数据队列 U^t ,数据未融合的原因是本车与数据提供者关系尚未建立.接收者接收数据包后,根据本地 L 查询ID从而确定是否与其建立起转换关系.若ID未被检索到,则进行多车坐标系统一,进行两车坐标转换关系的解算,此时数据包存入 U^t 等待转换关系计算结果.若ID被检索到,在 X 中找到对应的变换关系 X_j ,数据包的地图和位姿数据 M 将经过空间三轴旋转和平移变换得到 m_{ID} ,如式(2)所示, $R_{3 \times 3}$ 代表点云围绕三轴的翻滚、俯仰和航向角构成的旋转矩阵, T 代表点云在三轴的平移向量.处理后的 m_{ID} 融入本地地图,参与约束构建和后端优化过程.

$$m_{ID} = \begin{bmatrix} R_{3 \times 3} & T \\ 0 & 1 \end{bmatrix} \begin{bmatrix} M_x \\ M_y \\ M_z \\ 1 \end{bmatrix} \quad (2)$$

3.4 多车坐标系统一与数据融合

多车坐标系统一与数据融合过程如图3所示.在本地地图中搜索与其他车数据重叠的相似点云,进行点云配准计算坐标转换关系.若配准结果满足阈值则融合数据,并进行多车闭环检测和全局优化.否则,无法获得匹配结果,将数据包存储在 U^t 中,本地地图更新只包含自身SLAM数据.

点云配准将相似的源点云和目标点云作为输入,通过点对匹配与迭代计算点云间的旋转平移关系.将局部坐标系下的数据代入,求解坐标系转换关系.为了提高搜索速度,使用基于欧氏距离和点云特征描述子作为索引,将超参数 τ_1 作为阈值参数.为了提高匹配效率和精确度,采用由粗到精的配准方法.粗配准使用采样一致性配准算法,精配准使用最近点迭代算法.

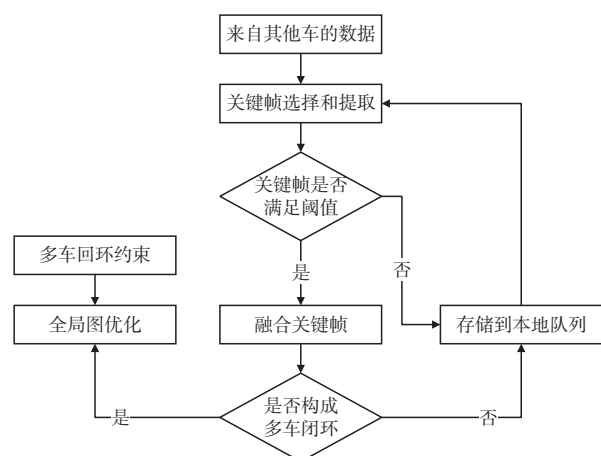


图3 多车坐标系统一与数据融合流程

为扩大多车建立坐标系转换关系的范围,基于变换矩阵的传递性使未通过重叠区域相似点云配准的车辆间接建立关系.接收者 r 根据数据包中的 L 获悉尚未与之建立关系的 s .基于变换矩阵的传递性, r 与 s 通过矩阵连乘的方式建立联系.转换关系建立后, r 与 s 更新自身的 L 和 X ,搜索 U^t 中尚未融合的数据,并融合数据.在这种情况下,本地地图更新包含自身SLAM数据,以及融合其他车数据.

3.5 多车协同SLAM的闭环检测与优化

通过引入图的连通分支和最小生成森林进行多车闭环检测,将多车SLAM数据抽象为生成森林,每辆车的轨迹是森林的连通分支.初始情况,生成森林以车辆数为单位构建连通分支.每辆车的初始关键帧作为当前连通分支的第一个节点.接下来,更多关键帧根据车辆ID加入对应连通分支,此时生成森林的结构形如多条独立链表.

图4展示多车协同SLAM的闭环检测过程.图4(a)描述了3辆车的初始位姿.如图4(b)所示,随着观测与建图,连通分支增加更多节点.如图4(c)所示,当不同连通分支节点相互靠近甚至重合时,不同车辆发生轨迹重合.两个节点构建相对观测约束,森林中独立的两个连通分支被合并,连通分支的数量减少,触发全局闭环检测.如图4(d)所示,当多车已进行充分数据交换,多车间构建坐标系转换关系,连通分支构建相对观测约束.随着新的相对观测约束产生,触发基于当前节点

的全局回环检测.由于多节点构成的大回环引入更多误差,因此在多车协同后端优化中优化搜索到的最小回环.

最小回环搜索算法如算法1所示,将多车连通分支构成集合 C ,多车间相对观测约束集合 R 以及最新属于不同连通分支的两个节点 i 和 j 之间的相对观测 $r_{i,j}$ 作为输入.针对 i ,将其所处的回环数目以及每个回环包含节点编号集合作为结果输出.当两个节点属于同一分支,直接返回两个节点间的节点集合.否则使用基于深度递归的连通分支可达性搜索找到两个节点间的节点集合.

算法1 最小回环搜索算法

输入:连通分支集合 C ,相对观测约束集合 R ,相对观测约束 $r_{i,j}$

输出:回环个数,最小回环节点编号集合

$G \leftarrow \{0\}$

IF i 和 $j \in$ 同一个连通分支 THEN

RETURN $(G \cup \{j-i+1\}, 1)$

ELSE

FOR $k=i$ 遍历至连通分支 g 结束

IF $k \in R_{\{i, \dots, m\}}$ THEN

set=DFS($C \setminus g, R \setminus m, r_{i,j}$)

$l \leftarrow \text{size}(\text{set}) + \|k-i\|$

set \leftarrow set $\cup \{i \dots k\}$

RETURN $(G \cup \text{set}_{\min(j)}, \text{size}(G))$

通过构建多车回环约束与寻找最小回环之后,开展后端优化.后端优化本质是求解非线性最小二乘问题,得到关于位姿的最优值,使整体误差函数达到最小,在本文框架中,使用的误差函数定义为:

$$F(x) = \sum e_k(x_k, z_k)^T \omega_k e_k(x_k, z_k) \quad (3)$$

x 是位姿集合, e_k 表示第 x_k 位姿和第 z_k 约束之间的误差,这些约束条件包括相对观测约束和全局回环约束. ω_k 是和 x_k 相关的信息矩阵,通过高斯牛顿法对式(4)的误差函数进行最小化迭代求解即可完成全局的后端优化过程.

4 实验结果与分析

为了验证多车协同SLAM框架,本节介绍真实场景与仿真下的实验以及对应的分析.本节的实验包括验证多车协同SLAM闭环检测与优化,对比其他多车融合方法与本文方法的结果,对比不同车数量多车协同场景以及探讨框架中超参数的影响.

真实场景下实验使用16线激光雷达感知环境,将惯性导航和实时动态载波相位差分数据(RTK)记录里程计作为真实值^[29].仿真场景使用KITTI数据集.评价指标使用真实值与实验值的均方根误差.




图4 图的连通分支和生成森林寻找最小回环过程

4.1 闭环场景实验

本章节介绍不同场景下多车SLAM闭环实验,验证本文提出框架的泛化性和可用性.图5展示第一个实验场景.该场景在真实场景下采集获得,场景包含河岸,桥梁,建筑,树林等,累积轨迹长度为690m.此场景下进行两车实验.

图5(a)展示原始两车融合后点云地图,图5(b)展示经过协同闭环检测优化后的地图,两图的融合细节与差别在图中用白框标记.从图可知,经过协同闭环检测及优化后的建筑物,桥梁和路沿融合效果较好,未经闭环检测和优化的地图在建筑物,桥梁和路沿等区域产生偏差.这是由于两次转换矩阵计算带有一定误差,影响多车数据融合.通过协同闭环检测,建立多车之间的约束纠正偏差.




图5 闭环检测前后地图对比结果

图6(a),图6(b),图6(c)给出闭环检测优化前后单车轨迹和协同闭环优化的轨迹.从图可知,单车经过局部闭环与优化,轨迹与真实值仍有差距,协同闭环与优化后的轨迹更接近真实值.

表1给出单车闭环检测优化前后和协同闭环优化前后轨迹误差定量对比结果.从表可知,单车SLAM和协同SLAM经过闭环检测优化,轨迹误差均有所下降.经过协同闭环优化后的准确率更高,相比单车闭环检测,误差降低17.14%.协同SLAM闭环检测优化前后,轨迹误差降低53.48%.此外,由于多车间坐标转换关系带有误差,因此需要闭环检测与优化进行纠正.

为了体现本文框架的泛化性,基于KITTI数据集^[30]开展不同场景实验,多车数量设置为2.场景包括林间

表1 真实场景实验结果

车数	优化前轨迹(m)	优化后轨迹(m)	RTK(m)	优化前误差(m)	优化后误差(m)	时间(s)
1	697.07	693.04	690.71	4.89	2.10	183
2	695.67	691.21	690.71	3.74	1.74	106

小路、乡村道路、快速公路、城市道路等. KITTI场景交通信息丰富,复杂度较高,车辆行驶较远,单车误差较大.实验结果如表2所示.由表可知,优化前单车SLAM误差最大,经过单车闭环检测优化之后,误差降低.多车协同通过降低累积距离以及多车协同闭环的方式进行优化,提升准确率.从实验场景分析,林间小路误差最高,该场景下树木繁盛相似度高,对特征提取和闭环检测及优化带来较大挑战.快速公路由于景物稀疏,同样不利于特征提取和匹配.乡村和城市道路效果较好,两旁的建筑物等特征景物,有利于多车协同SLAM.

表2 KITTI数据集实验结果

实验场景	单车优化前误差	单车优化后误差(m)	多车优化前误差(m)	多车优化后误差(m)
林间小路	17.09	12.43	13.91	9.39
快速公路	11.92	7.98	4.75	3.11
乡村道路	10.05	6.87	2.74	2.39
城市道路	7.24	5.56	2.90	2.65

4.2 融合方法对比实验

本文通过重叠点云配准完成坐标系转换和数据融合,本章节对比引入另一种融合方案.该方案直接基于多车起始位姿的GPS数据,将经纬度数据投影后的差值和转向数据差值构建平移向量和旋转矩阵.基于文献[9]开放数据集,选择园内道路和牌坊标志物两个场景进行实验.

图7展示园内道路下融合方法对比结果,结果包括轨迹图和地图融合结果的放大图.轨迹图中藏青色代表真实值,红色代表来自A车轨迹,蓝色和浅蓝色分别代表B车轨迹经过本文方案 and 对比方案结果,地图颜色与轨迹对应.从图可知,经过本文方法处理后的B车轨迹与RTK重合,且重叠区域点云融合结果明显更优.




图6 闭环检测前后轨迹对比结果




图7 园内道路场景下的融合方法对比

经过对比方案融合的B车轨迹与真实值存在较大差距,在平移方向产生较大误差,同一条道路在融合之后变为两条。此场景下,本文方案RMSE为1.52,对比方案RMSE为18.50。

图8展示牌坊标志物场景下的融合方法对比结果,颜色标识与图7相同。由图可知,本文方法融合后的B车轨迹与RTK更接近,经过对比方案融合后的B车轨迹与真实值存在旋转误差。此外,本文方案的两车在重叠区域点云融合结果优于对比方案。此场景下本文方案的RMSE为1.96,对比方案的RMSE为3.76。

综上所述,对比方案效果不及本文融合方案。首先,GPS由于多重反射及信号阻挡带有误差;其次,GPS在投影及构建转换矩阵过程存在损失。而本文融合方案基于重叠区域的相似点云地图配准,计算转换关系更为准确。

4.3 多车数量对比实验

本章基于真实采集数据和KITTI数据集,对比不同数量车参与协同SLAM结果。真实场景下采集数据包

含树林,建筑以及河岸等景物。

图9给出该场景下不同数目车辆协同SLAM结果。图9(b)至图9(e),不同颜色地图代表全局地图由不同车数据组成,每辆车起点和终点已标出。图9(f)至图9(i)对应展示轨迹。由图可知,随着车数量增多,闭环检测优化之后轨迹与真实值越接近。

表3给出该场景下的量化结果。由表3可知,该场景下的任务,完成时间降低72%,效率提升。在精度方面,误差降低4.9%,随着车数量增加,误差下降。这是由于车数量增加,累积距离更短,误差更小。此外,多车建立更多相对观测和闭环约束,经过全局闭环检测与优化后纠正偏差。

表4展示KITTI数据集下的结果。为了设计多车协同场景,按照车数量切割该数据包以模拟多车。该场景较为复杂,多车间包含较多重叠区域。结果显示,随着车数量增加,多车轨迹长度增加,协同时间降低,优化后的误差降低。这表明,本文的协同框架提升了算法准确率。




图8牌坊标志物场景下的融合方法对比

表3 真实场景下车数量对比实验结果

车数量	多车轨迹(m)	多车 RTK(m)	误差(m)	时间(s)
1	1511.69	1508.21	2.27	459
2	1552.31	1553.76	2.18	250
3	1617.85	1620.62	2.17	170
4	1618.87	1621.05	2.16	128

表4 KITTI数据集车数量对比实验结果

车数量	多车轨迹(m)	多车 RTK(m)	误差(m)	时间(s)
1	3462.09	3745.86	12.05	287
2	3731.09	3912.56	9.39	160
3	4809.99	5183.82	7.12	110
4	5381.96	5652.58	4.56	99
5	7716.39	7981.87	4.32	86

4.4 超参数验证实验

为了探讨框架中超参数 τ_0 和 τ_1 的影响,本章节进行超参数实验。 τ_0 表示发送者生成数据包的节点数量,节点越多,点云匹配特征越多,匹配结果更精确。过多节点导致点云相似度低、配准计算量大等问题。 τ_1 是判断重叠区域的阈值,该阈值设置过大导致误匹配,设置

过小则导致匹配难以成功。

本文使用3辆车进行协同SLAM,改变 τ_0 和 τ_1 分析对结果的影响。为了定量探究超参数影响情况,本文选择匹配分数,数据包大小以及匹配时间作为评判标准。经过预实验后,本文选取 τ_0 变化范围为1~8, τ_1 变化范

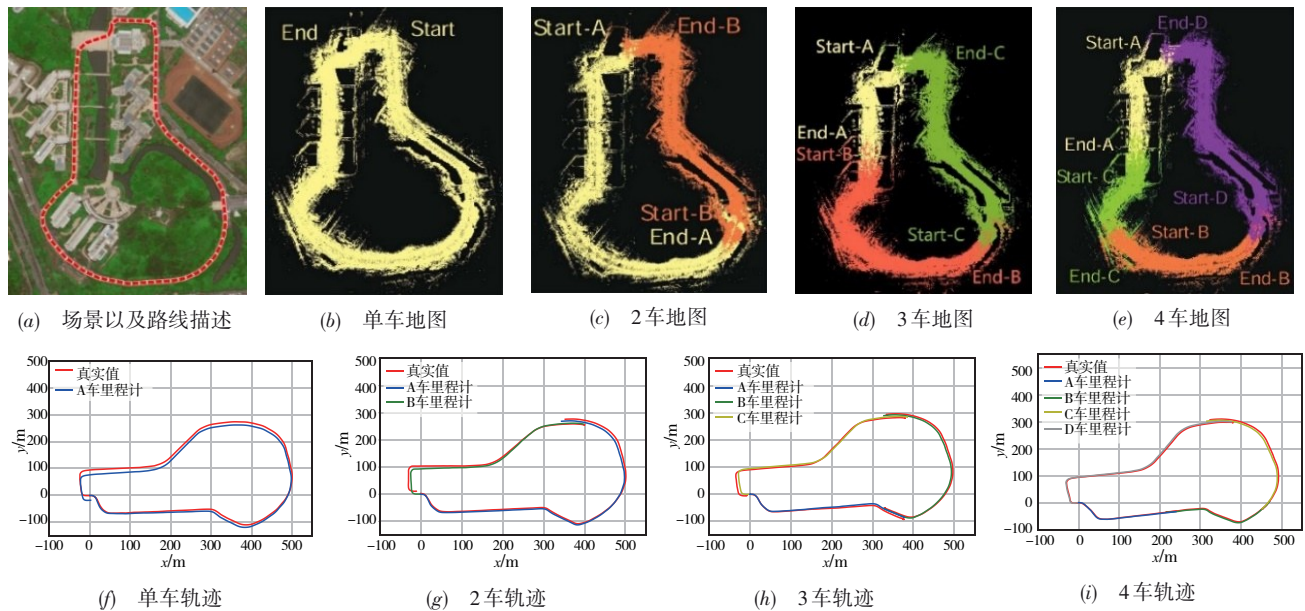


图9 不同数量多车协同SLAM结果

围为 1.5~3.5, 图 10 展示了实验结果. 匹配分数是目标点云与匹配后点云点对的距离平方和, 匹配分数越低表示结果越准确. 由图 10(a) 可知, 匹配分数随着 τ_1 增加而增加. τ_1 增加表明重叠区域判定条件更为宽松, 配准点云包含更多非重叠区域的特征, 配准准确率降低. 当 τ_0 超过 5 时, 车距离较远, 数据包内包含较多非重叠区域特征, 匹配结果不理想. 由图 10(b) 可知, 数据包大小随 τ_0 增加而增加, τ_1 对数据包大小不产生影响. 由图 10(c) 可知, 匹配时间随着 τ_0 增加而增加, 这是因为点云数据量增加, 点云包含非重叠区域的特征, 在匹配过程中迭代时间增长. 根据图 10 的实验结果, 综合匹配分数, 数据包大小以及匹配时间等指标, 将 τ_0 设置为 3~5, 将 τ_1 设置为 1.5.

车辆行驶速度产生稀疏程度不同的点云, 进而影

响配准结果. 为探究车速影响, 在仿真场景下比较不同车速的影响, 选取优化后误差和匹配分数作为评价指标, 实验结果如表 5 所示. 由表可知, 该场景下将车速设为 9.6 km/h, 点云匹配最准确. 车速较低时, 重叠区域点云密度过大, 配准过程增加更多噪声点导致配准分数降低. 车速较高时, 重叠区域点云密度过低, 点云内特征点少, 配准准确率降低. 针对不同车速, 通过动态调整 τ_0 和 τ_1 改变重叠区域点云密度, 保证协同 SLAM 的准确率.

表 5 平均车速对比实验结果

	平均车速(km/h)						
	4.2	6.9	9.6	12.3	13.7	15.1	18.9
优化后误差(m)	2.14	1.91	1.74	1.89	2.05	2.12	2.29
匹配分数	0.81	0.71	0.41	0.59	0.73	0.77	1.15




图 10 超参数对实验结果的影响

5 结论

本文提出面向自动驾驶的多车协同 SLAM 框架, 该框架基于重叠区域点云配准和转换矩阵传递性建立多车坐标系转换关系. 采用图的连通分支和最小生成森林理论进行多车闭环检测, 进而完成后端全局优化. 真实场景与数据集下的实验结果表明本文框架在运行效率和准确率上具有优势.

参考文献

- [1] Deschaud J E. IMLS-SLAM: Scan-to-model matching based on 3D data [A]. 2018 IEEE International Conference on Robotics and Automation[C]. Australia: IEEE, 2018.2480 – 2485.
- [2] Park C, Moghadam P, Kim S, et al. Elastic LiDAR fusion: Dense map-centric continuous-time SLAM [A]. 2018 IEEE International Conference on Robotics and Automation[C]. Australia: IEEE, 2018. 1206 – 1213.
- [3] 弋英民, 刘丁. 有色过程噪声下的轮式机器人同步定位与地图构建[J]. 电子学报, 2010, 38(6): 1339 – 1343.
- [4] Choudhary S, Carlone L, Nieto C, et al. Distributed trajectory estimation with privacy and communication constraints: A two-stage distributed Gauss-Seidel approach [A]. 2016 IEEE International Conference on Robotics and Automation[C]. Sweden: IEEE, 2016.5261 – 5268.
- [5] Dabeer O, Ding W, Gowaiker R, et al. An end-to-end system for crowdsourced 3D maps for autonomous vehicles: The mapping component [A]. 2017 IEEE/RSJ International Conference on Intelligent Robots and Systems[C]. Canada: IEEE, 2017.634 – 641.
- [6] Andre T, Neuhold D, Bettstetter C. Coordinated multi-robot exploration: Out of the box packages for ROS [A]. 2014 IEEE Globecom Workshops[C]. Austin, USA: IEEE, 2014.1457 – 1462.
- [7] Cunningham A, Paluri M, Dellaert F. DDF-SAM: fully distributed slam using constrained factor graphs[A]. 2010

Yi Y M, Liu D. Colored-state-noise simultaneous localization and map building for wheel robots[J]. Acta Electronica Sinica, 2010, 38(6): 1339 – 1343.(in Chinese)

- IEEE International Conference on Intelligent Robots and Systems[C]. Taipei, China: IEEE, 2010. 3025 – 3030.
- [8] Nieto-Granda C, Rogers J G III, Christensen H I. Coordination strategies for multi-robot exploration and mapping[J]. The International Journal of Robotics Research, 2014, 33(4): 519 – 533.
- [9] Zhe X Y, Li B Y, Zhang X Y, et al. Online cooperative 3d mapping for autonomous driving[A]. 2018 IEEE Intelligent Vehicles Symposium[C]. Changshu, China: IEEE, 2018. 256 – 261.
- [10] Zhang J, Singh S. Loam: lidar odometry and mapping in real-time[EB/OL]. <http://www.roboticsproceedings.org/rss10/p07.pdf> 2019.11.10.
- [11] Shan T X, Englot B. LeGO-LOAM: lightweight and ground-optimized lidar odometry and mapping on variable terrain[A]. 2018 IEEE International Conference on Intelligent Robots and Systems[C]. Madrid, Spain: IEEE, 2018. 4758 – 4765.
- [12] Khairuddin A R, Talib M S, Haron H. Review on simultaneous localization and mapping (slam)[A]. 2015 IEEE International Conference on Control System, Computing and Engineering[C]. Penang, Malaysia: IEEE, 2018. 85 – 90.
- [13] Sun Q X, Yuan J, Zhang X B, et al. RGB-D SLAM in indoor environments with STING-based plane feature extraction[J]. IEEE/ASME Transactions on Mechatronics, 2018, 23(3): 1071 – 1082.
- [14] Sun Q X, Yuan J, Zhang X B, et al. Plane-edge-SLAM: Seamless fusion of planes and edges for SLAM in indoor environments[J]. IEEE Transactions on Automation Science and Engineering, 2021, 18(4): 2061 – 2075.
- [15] 梁明杰, 闵华清, 罗荣华. 基于图优化的同时定位与地图创建综述[J]. 机器人, 2013, 35(4): 500 – 512.
- Liang M J, Min H Q, Luo R H. Graph-based slam: A survey[J]. Robot, 2013, 35(4): 500 – 512.(in Chinese)
- [16] Grisetti G, Kümmerle R, Stachniss C, et al. A tutorial on graph-based SLAM[J]. IEEE Intelligent Transportation Systems Magazine, 2010, 2(4): 31 – 43.
- [17] 陈凤东, 洪炳镕. 基于特征地图的移动机器人全局定位与自主泊位方法[J]. 电子学报, 2010, 38(6): 1256–1261.
- Chen F D, Hong B R. A global localization and self-docking method for mobile robot based on feature map[J]. Acta Electronica Sinica, 2010, 38(6): 1256 – 1261.(in Chinese)
- [18] 石杏喜, 赵春霞, 郭剑辉. 基于PF/CUKF/EKF的移动机器人SLAM框架算法[J]. 电子学报, 2009, 37(8): 1865 – 1868.
- Shi X X, Zhao C X, Guo J H. The framework algorithm for mobile robot simultaneous localization and mapping based on PF/CUKF/EKF[J]. Acta Electronica Sinica, 2009, 37(8): 1865 – 1868.(in Chinese)
- [19] Olson E, Leonard J, Teller S. Fast iterative alignment of pose graphs with poor initial estimates[A]. 2006 IEEE International Conference on Robotics and Automation[C]. Orlando, USA: IEEE, 2006. 2262 – 2269.
- [20] Grisetti G, Kümmerle R, Stachniss C, et al. Hierarchical optimization on manifolds for online 2d and 3d mapping [A]. 2010 IEEE International Conference on Robotics and Automation[C]. Anchorage, USA: IEEE, 2010. 273 – 278.
- [21] Reid S, et al. Coordination for multi-robot exploration and mapping[A]. Proceedings of the 17th National Conference on Artificial Intelligence and 12th Conference on Innovative Applications of Artificial Intelligence [C]. Austin, USA: ACM, 2000. 852 – 858.
- [22] Zhang Y C, Chen L, XuanYuan Z, et al. Three-dimensional cooperative mapping for connected and automated vehicles[J]. IEEE Transactions on Industrial Electronics, 2020, 67(8): 6649 – 6658.
- [23] Indelman V, Nelson E, Michael N, et al. Multi-robot pose graph localization and data association from unknown initial relative poses via expectation maximization[A]. 2014 IEEE International Conference on Robotics and Automation[C]. Hong Kong, China: IEEE, 2014.593 – 600.
- [24] Riazuelo L, Civera J, Montiel J M M. C2TAM: A cloud framework for cooperative tracking and mapping[J]. Robotics and Autonomous Systems, 2014, 62(4): 401 – 413.
- [25] Aragues R, Carlone L, Calafiore G, et al. Multi-agent localization from noisy relative pose measurements[A]. 2011 IEEE International Conference on Robotics and Automation[C]. Shanghai, China: IEEE, 2011. 364 – 369.
- [26] Wen J, Zhang X B, Gao H M, et al. CAE-RLSM: Consistent and efficient redundant line segment merging for on-line feature map building[J]. IEEE Transactions on Instrumentation and Measurement, 2020, 69(7): 4222 – 4237.
- [27] Thrun S. A probabilistic on-line mapping algorithm for teams of mobile robots[J]. The International Journal of Robotics Research, 2001, 20(5): 335 – 363.
- [28] Cunningham A, Indelman V, Dellaert F. DDF-SAM 2.0: Consistent distributed smoothing and mapping [A]. 2013 IEEE International Conference on Robotics and Automation[C]. Karlsruhe, Germany: IEEE, 2013. 5220 – 5227.
- [29] 高洪波, 张新钰, 张天雷, 等. 基于云模型的智能驾驶车辆变粒度测评研究[J]. 电子学报, 2016, 44(2): 365 – 373.

Gao H B, Zhang X Y, Zhang T L, et al. Research of intelligent vehicle variable granularity evaluation based on cloud model[J]. Acta Electronica Sinica, 2016, 44(2): 365v373.(in Chinese)

- [30] Geiger A, Lenz P, Urtasun R. Are we ready for autonomous driving? The KITTI vision benchmark suite[A]. 2012 IEEE International Conference on Computer Vision and Pattern Recognition[C]. Providence, USA: IEEE, 2012. 3354 – 3361.

作者简介




李博洋 男,1994年5月生于辽宁鞍山,现为中山大学计算机学院博士研究生,研究方向为三维环境感知.

E-mail:liby3@mail2.sysu.edu.cn



刘思健 男,1993年6月生于广东湛江,现为中山大学计算机学院硕士研究生,研究方向为多机器人协同SLAM.

E-mail:liusj37@mail2.sysu.edu.cn



崔明月 男,1992年11月生于山东淄博,现为中山大学计算机学院博士研究生,研究方向为智能机器人与边缘计算.

E-mail:cuimy@mail2.sysu.edu.cn



赵治豪 男,1996年3月生于河南驻马店,现为中山大学深圳研究院硕士研究生,研究方向为智能机器人.

E-mail:zhaozh25@mail2.sysu.edu.cn



黄凯(通信作者) 男,1977年10月生于广西梧州,现为中山大学计算机学院教授,博士生导师,研究方向为无人系统与智能机器人.

E-mail:huangk36@mail.sysu.edu.cn